

INFORMATION CLUSTERING

Fandy Setyo Utomo, S.Kom., M.Cs., Ph.D

PSIFW025 – Temu Balik Informasi

Program Studi Informatika - Universitas AMIKOM Purwokerto

Capaian Pembelajaran Praktikum:

Mahasiswa menerapkan teknik information clustering (pengelompokkan informasi) untuk menangani information overload (kelebihan informasi).

Software yang diperlukan dalam pembelajaran:

1. Anaconda (<https://www.anaconda.com/download>)
2. Python
3. Spyder (*Scientific Python Development Environment*) 4.1.5
4. XAMPP: MySQL database
5. Database 'quran' dari file SQL pertemuan 2: *id.indonesian*
6. mysql-connector-python
7. Sastrawi (<https://pypi.org/project/Sastrawi/>)
8. Natural Language Toolkit (<https://pypi.org/project/nltk/>)

Praktikum:

1. Terdapat beberapa modul python yang dibuat pada praktikum materi *information clustering*. Urutan pembuatan modul dan penjelasannya masing-masing dideskripsikan sebagai berikut:
 - a. Modul *database.py*

Modul ini berfungsi mengatur koneksi antara python dengan database MySQL. Selain itu, modul ini juga berfungsi untuk melakukan operasi pengolahan data di dalam database.
 - b. Modul *textPreProcessing.py*

Modul ini berfungsi untuk melakukan pra-pemrosesan teks seperti punctuation removal, lowercase operation, stopwords removal, dan operasi stemming.
 - c. Modul *cluster.py*

Modul ini berfungsi untuk memroses *information clustering* (pengelompokkan informasi) menggunakan algoritma K-Means. Selain itu, modul ini juga berfungsi untuk menampilkan informasi pengelompokkan informasi menggunakan algoritma tersebut.

d. File utama *modulUtama.py*

File ini berfungsi sebagai file utama yang meng-*import* seluruh modul yang telah dibuat sebelumnya. Selain itu, file ini juga berfungsi untuk menerima entri data kueri pengguna.

2. Ketikkan kode program Python berikut pada IDE Spyder. Lalu, simpan dan beri nama *database.py*

```
1. '''
2. Create class 'DatabaseConnection' to handle query operation and
3. connection between python and MySQL database.
4. '''
5. import mysql.connector
6. from mysql.connector import errorcode
7.
8. config = {
9.     'user' : 'root',
10.    'database' : 'quran'
11.}
12.
13. class DatabaseConnection():
14.
15.    #Constructor
16.    def __init__(self):
17.
18.        try:
19.            #Create database connection
20.            self.db_connect = mysql.connector.connect(**config)
21.
22.            #Create a Cursor
23.            self.cursor = self.db_connect.cursor()
24.
25.        except mysql.connector.Error as err:
26.
27.            if err.errno == errorcode.ER_ACCESS_DENIED_ERROR:
28.                print("Something is wrong with your user name or password")
29.            elif err.errno == errorcode.ER_BAD_DB_ERROR:
30.                print("Database does not exist")
31.            else:
32.                print(err)
33.
34.    def Select(self, query):
35.
36.        self.cursor.execute(query)
37.        self.data = self.cursor.fetchall()
```

```

38.         return self.data
39.
40.     #Destructor
41.     def __del__(self):
42.
43.         #Close Cursor
44.         self.cursor.close()
45.
46.         #Close DB Connection
47.         self.db_connect.close()
48. #=====End
49.
50. '''
51. Ambil data nomor index, surat, ayat, dan teks ayat dari tabel id_indonesian
52. '''
53. def getData(sql_query):
54.
55.     db = DatabaseConnection()
56.     query = (sql_query)
57.     data = db.Select(query)
58.     return data
59. #=====End

```

3. Ketikkan kode program Python berikut pada IDE Spyder. Lalu, simpan dan beri nama *textPreProcessing.py*

```

1. '''
2. Perform text pre-processing: punctuation removal, lowercase operation,
3. stopwords removal, and stemming operation
4. '''
5. def textprocessing(data):
6.
7.     #Regular expression operations: https://docs.python.org/3/library/re.html
8.     import re
9.
10.    #Dokumentasi Sastrawi Stemmer: https://pypi.org/project/Sastrawi/
11.    #import StopWordRemoverFactory class
12.    from Sastrawi.StopWordRemover.StopWordRemoverFactory import
    StopWordRemoverFactory
13.
14.    factory = StopWordRemoverFactory()
15.    stopword = factory.create_stop_word_remover()
16.
17.    #Create stemmer
18.    from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

```

```
19.
20.     factory = StemmerFactory()
21.     stemmer = factory.create_stemmer()
22.
23.     #Create an empty list of corpus
24.     corpus = []
25.
26.     for (index, sura, aya, text) in data:
27.         # [^a-zA-Z] means: eliminate number and punctuation, except alphabet
a-z and A-Z
28.         review = re.sub('[^a-zA-Z]', ' ', text)
29.
30.         #Lowercase operation
31.         review = review.lower()
32.
33.         #Stopwords removal operation
34.         review = stopwords.remove(review)
35.         jumlah_kata_awal = len(review.split())
36.         kondisi = True
37.         while(kondisi):
38.             review = re.sub(' +', ' ', review)
39.             review = stopwords.remove(review)
40.
41.             jumlah_kata_baru = len(review.split())
42.             if(jumlah_kata_awal == jumlah_kata_baru):
43.                 kondisi = False
44.             else:
45.                 jumlah_kata_awal = jumlah_kata_baru
46.
47.         #Stemming operation
48.         review = stemmer.stem(review)
49.
50.         #Add data quran verses to List
51.         corpus.append((index, sura, aya, review))
52.
53.     return corpus
```

4. Ketikkan kode program Python berikut pada IDE Spyder. Lalu, simpan dan beri nama *cluster.py*

```
1. # Import library yang diperlukan
2. import pandas as pd
3. from sklearn.feature_extraction.text import TfidfVectorizer
4. from sklearn.cluster import KMeans
5.
6. # Fungsi untuk melakukan clustering dan menampilkan hasil
7. def perform_clustering(documents, num_clusters, data, all_docs):
8.
9.     # Inisialisasi vectorizer TF-IDF
10.    vectorizer = TfidfVectorizer()
11.
12.    # Membuat matriks TF-IDF dari dokumen
13.    tfidf_matrix = vectorizer.fit_transform(documents)
14.
15.    # Melakukan clustering menggunakan k-means
16.    kmeans = KMeans(n_clusters=num_clusters, random_state=42)
17.    kmeans.fit(tfidf_matrix)
18.
19.    # Menambahkan label klaster ke data dokumen
20.    documents_df = pd.DataFrame({'Document': documents, 'Cluster': kmeans.labels_})
21.
22.    # Menambahkan kolom data untuk menyimpan teks hasil pemrosesan di setiap tuple
23.    updated_list = []
24.    for idx, tup in enumerate(data):
25.        updated_tuple = tup + (all_docs[idx],)
26.        updated_list.append(updated_tuple)
27.
28.    # Menampilkan hasil clustering
```

```
29.     print("\n=== Hasil Clustering ===")
30.     for cluster_num in range(num_clusters):
31.         cluster_documents = documents_df[documents_df['Cluster'] == cluster_num]['Document']
32.
33.         print(f'\nCluster {cluster_num + 1}:\n')
34.         x=1
35.         for doc in cluster_documents:
36.
37.             for (index, sura, aya, originalText, textpreprocess) in updated_list:
38.                 if(textpreprocess == doc):
39.                     print(f'{x}. No. Surah: {sura}, No. Ayat: {aya}, Tafsir: {originalText}')
40.                     break
41.
42.             x+=1
43.
44.         print('-----')
```


5. Ketikkan kode program Python berikut pada IDE Spyder. Lalu, simpan dan beri nama *modulUtama.py*

```
1. import database
2. import textPreProcessing
3. import cluster
4.
5. # Ambil data nomor index, surat, ayat, dan teks ayat dari tabel id_indonesian
6. query = "SELECT * FROM id_indonesian limit 200"
7. data = database.getData(query)
8.
9. # Pra-pemrosesan text: punctuation removal, lowercase operation,
10. # stopwords removal, dan operasi stemming
11. corpus = textPreProcessing.textprocessing(data)
12.
13. documents = []
14. for (index, sura, aya, text) in corpus:
15.     documents.append(text)
16.
17. # Program utama
18. if __name__ == "__main__":
19.
20.     # Pengguna menginputkan query
21.     query = input("Masukkan query: ")
22.
23.     # Menentukan jumlah klaster yang diinginkan
24.     num_clusters = 3
25.
26.     # Melakukan filtering dokumen berdasarkan keywords
27.     filtered_documents = [doc for doc in documents if query.lower() in doc.lower()]
28.
```



```
29.     # Memastikan ada cukup dokumen untuk dilakukan clustering
30.     if len(filtered_documents) >= num_clusters:
31.
32.         # Melakukan clustering dan menampilkan hasil
33.         cluster.perform_clustering(filtered_documents, num_clusters, data, documents)
34.     else:
35.         print("Tidak cukup dokumen untuk melakukan clustering.")
```

6. Eksekusi kode program tersebut dan amati luaran yang diberikan oleh program.
Berikut contoh luaran program yang diberikan:



```
IPython Console
Console 1/A x
Masukkan query: surga
=== Hasil Clustering ===
Cluster 1:
1. No. Surah: 2, No. Ayat: 94, Tafsir: Katakanlah: "Jika kamu (menganggap bahwa) kampung akhirat (surga) itu khusus untukmu di sisi Allah, bukan untuk orang lain, maka inggilah kematian(mu), jika kamu memang benar.
2. No. Surah: 2, No. Ayat: 111, Tafsir: Dan mereka (Yahudi dan Nasrani) berkata: "Sekali-kali tidak akan masuk surga kecuali orang-orang (yang beragama) Yahudi atau Nasrani". Demikian itu (hanya) angan-angan mereka yang kosong belaka. Katakanlah: "Tunjukkanlah bukti kebenaranmu jika kamu adalah orang yang benar".
-----
Cluster 2:
1. No. Surah: 2, No. Ayat: 35, Tafsir: Dan Kami berfirman: "Hai Adam, diamlah oleh kamu dan isterimu surga ini, dan makanlah makanan-makanannya yang banyak lagi baik dimana saja yang kamu sukai, dan janganlah kamu dekati pohon ini, yang menyebabkan kamu termasuk orang-orang yang zalim.
2. No. Surah: 2, No. Ayat: 36, Tafsir: Lalu keduanya digelincirkan oleh syaitan dari surga itu dan dikeluarkan dari keadaan semula dan Kami berfirman: "Turunlah kamu! sebagian kamu menjadi musuh bagi yang lain, dan bagi kamu ada tempat kediaman di bumi, dan kesenangan hidup sampai waktu yang ditentukan".
3. No. Surah: 2, No. Ayat: 38, Tafsir: Kami berfirman: "Turunlah kamu semuanya dari surga itu! Kemudian jika datang petunjuk-Ku kepadamu, maka barang siapa yang mengikuti petunjuk-Ku, niscaya tidak ada kekhawatiran atas mereka, dan tidak (pula) mereka bersedih hati".
-----
Cluster 3:
1. No. Surah: 2, No. Ayat: 25, Tafsir: Dan sampaikanlah berita gembira kepada mereka yang beriman dan berbuat baik, bahwa bagi mereka disediakan surga-surga yang mengalir sungai-sungai di dalamnya. Setiap mereka diberi rezeki buah-buahan dalam surga-surga itu, mereka mengatakan: "Inilah yang pernah diberikan kepada kami dahulu". Mereka diberi buah-buahan yang serupa dan untuk mereka di dalamnya ada isteri-isteri yang suci dan mereka kekal di dalamnya.
2. No. Surah: 2, No. Ayat: 82, Tafsir: Dan orang-orang yang beriman serta beramal saleh, mereka itu penghuni surga; mereka kekal di dalamnya.
-----
```